

文章编号:1672-4747(2025)01-0006-11

基于大语言模型的多模式出行方案个性化推荐

李文翔¹, 丁龙远¹, 张逸文¹, 张行光¹, 刘蓓¹, 陈培焱^{*2}

(1. 上海理工大学, 管理学院, 上海 200093; 2. 浙江大学, 计算机科学与技术学院, 杭州 310027)

摘要:【背景】现有的出行推荐系统大多是根据特定目标,对各种交通方式的出行方案进行同质化推荐,未能考虑用户出行情景的异质性,导致难以满足用户个性化的出行需求。【目标】提出一种基于大语言模型的多模式出行方案个性化推荐算法,通过时空上下文感知,将多维异构的个性化出行情景表征为统一空间的嵌入向量,以更精准地刻画用户的出行需求,从而为用户推荐最匹配的出行方案。【数据】基于百度地图的历史出行大数据,提取用户出行查询记录、出行方案推荐记录、点击记录和用户属性等信息。【方法】利用BERT(Bidirectional Encoder Representations from Transformers)大语言模型将用户每次查询所对应的推荐出行方案集文本描述转化为语义向量,并与出行时段、用户属性等特征进行融合,构建综合表征用户个性化出行情景时空异质性的特征向量。将个性化出行情景特征向量输入多层感知器(Multilayer Perceptron, MLP)模型,预测用户最有可能选择的交通方式,作为推荐的最佳出行方案。【结果】基于BERT语义嵌入与MLP构建的多模式出行方案个性化推荐模型能够较为精确地辨识用户的差异化出行需求,其加权F1分数高于已有研究中使用相同数据集的其他模型。【应用】应用大语言模型感知用户个性化出行情景,可以显著提升出行推荐系统的智能化和个性化水平,对于优化出行服务质量,提高用户出行满意度具有重要作用。

关键词:智能交通;出行方案推荐;大语言模型;多模式出行;个性化出行情景

中图分类号:U121; TP18 **文献标志码:**A **DOI:** 10.19961/j.cnki.1672-4747.2024.11.022

Personalized recommendation of multimodal travel schemes based on large language models

LI Wenxiang¹, DING Longyuan¹, ZHANG Yiwen¹, ZHANG Xingguang¹,
LIU Bei¹, CHEN Peiyan^{*2}

(1. Business School, University of Shanghai for Science and Technology, Shanghai 200093, China;
2. College of Computer Science and Technology, Zhejiang University, Hangzhou 310027, China)

Abstract: 【Background】 Existing travel recommendation systems typically offer homogenized recommendations for various transportation modes based on specific objectives without considering the heterogeneity of users' travel contexts, making it difficult to meet personalized travel demands. 【Objective】 Propose a personalized multimodal travel recommendation algorithm based on a large language model. Through spatiotemporal context perception, the algorithm represents heterogeneous personalized travel scenarios as embedding vectors in a unified space, thereby accurately capturing

收稿日期:2024-11-23

录用日期:2024-12-10

网络首发:2024-12-16

审稿日期:2024-11-23~2024-12-01; 2024-12-10

基金项目:国家自然科学基金项目(72471149);教育部人文社会科学研究项目(24YJCZH147);上海市哲学社会科学规划青年课题(2023EKC003);上海市教育委员会“人工智能促进科研范式改革赋能学科跃升计划专项”

作者简介:李文翔(1992—),男,副教授,研究方向为智慧出行服务、低碳交通规划、共享交通管理等, E-mail: liwx@usst.edu.cn

通信作者:陈培焱(1993—),男,博士后,研究方向为智慧交通、智慧出行等, E-mail: chenpy_tju@163.com

引文格式:李文翔,丁龙远,张逸文,等.基于大语言模型的多模式出行方案个性化推荐[J].交通运输工程与信息学报,2025,23(1):93-103.

LI Wenxiang, DING Longyuan, ZHANG Yiwen, et al. Personalized recommendation of multimodal travel schemes based on large language models[J]. Journal of Transportation Engineering and Information, 2025, 23(1): 93-103.

users' travel demands and recommending the most suitable travel options. **[Data]** Based on historical travel data from Baidu Maps, user travel query records, travel plan recommendation records, click records, and user attributes were extracted. **[Methods]** The large language model BERT (Bidirectional Encoder Representations from Transformers) was utilized to convert the text descriptions of recommended travel plans corresponding to each user query into semantic vectors and integrate them with travel time periods, user attributes, and other features to construct a comprehensive feature vector that represents the spatiotemporal heterogeneity of individualized travel scenarios. The personalized travel scenario feature vectors were input into the multilayer perceptron (MLP) to predict the most likely mode of transportation that users will choose as the recommended optimal travel plan. **[Results]** The multimodal travel plan personalization recommendation model built with BERT semantic embedding and MLP can accurately identify the differentiated travel demands of users, with a weighted F1 score higher than that of other models using the same dataset in existing research. **[Application]** Applying large language models to perceive user-specific travel scenarios can significantly enhance the intelligence and personalization levels of travel recommendation systems, which is of great importance for optimizing travel service quality and improving user travel satisfaction.

Key words: intelligent transportation; travel plan recommendation; large language mode; multimodal travel; personalized travel scenarios

0 引言

多模式出行方案推荐系统旨在根据用户指定的起始地和目的地,规划涵盖步行、自行车、驾车、地铁、公共汽车等多种交通方式的出行方案供用户选择^[1]。然而,现有的出行推荐系统,如高德地图、百度地图等提供的出行规划服务,大多是基于时间最短、距离最短或费用最低等固定目标,为相同起终点的用户提供同质化的出行方案推荐服务,未能根据不同出行情景和用户偏好进行个性化调整,导致推荐的方案可能并非用户真正想选择的。例如,对于相同的出行起点和终点,年轻人可能倾向于选择自行车,而老年人可能倾向于选择公交车;即使是对于相同的用户去同一地点,在工作日早晚高峰时段他可能倾向于选择地铁以避免拥堵,而在周末的平峰时段,他则可能倾向于选择驾车以携带更多家庭成员。可见,用户的每一次出行查询均蕴含着丰富的时空上下文信息,但目前出行推荐系统未能全面考虑这些信息,因此难以较好地满足用户个性化的出行需求^[2]。

已有研究通过分析用户历史轨迹、出行偏好、实时交通等多种数据,旨在为用户提供最佳的出行方案。例如,Liu等^[3]根据实时交通状况、道路危险和驾驶员偏好动态调整推荐路线,提供最优小汽车出行方案;Herzog等^[4]利用协同过滤和基于知识的方法,分析实时交通信息,为用户推荐最优的

单一模式出行方案;Du等^[5]通过广度优先搜索算法,以最低出行成本为优化目标,为用户在特定的单一交通方式中推荐最优公共交通出行方案;Socharoentum等^[6]根据用户的步行偏好、目的地和周围环境,通过多标准决策方法为用户推荐最适合的步行路线;Dai等^[7]和段宗涛等^[8]通过分析用户的历史出行轨迹和行为模式,推荐高效的单一模式出行方案;Chen等^[9]通过对特定交通方式的历史轨迹数据进行聚类 and 模式识别,提取出在单一出行模式下最受欢迎的路径,帮助用户找到高效的出行方案。

尽管上述研究在出行方案推荐领域取得了一定成效,但由于这些方案大多基于单一交通方式且未充分考虑用户具体出行情景,因此常常无法提供满意的用户体验,难以满足用户多样化的出行需求。为了解决这些问题,Liu等^[10]从大规模地图查询数据中构建多式联运图,并对不同交通方式进行嵌入学习,结合用户出行偏好和实时交通信息,为用户提供个性化的多模式出行方案;Wu等^[11]基于机器学习方法动态调整推荐结果,通过优化交通方式组合实现了多模式出行方案的个性化推荐;孙全明等^[12]提出了一种基于图嵌入和级联梯度提升决策树(CaGBDT)的多模式出行推荐方法,实现多模式出行特征的深层次表征学习。然而,由于出行推荐系统往往提供多个出行方案供用户

选择,不同方案之间存在复杂的时空依赖性,已有研究仅依据用户已选择的出行方案提取特征进行模型训练,无法全面考虑出行方案集中所蕴含的时空上下文关系,导致已有推荐模型难以精准刻画用户的个性化出行需求。

随着BERT、GPT等基于Transformer架构的大语言模型快速发展,其在处理复杂时空数据和解析出行行为背后的潜在联系方面展现出巨大的潜力^[13-14]。例如,Jin等^[15]提出一种基于BERT的交通流预测模型TrafficBERT,使用多头自注意力来捕获时间序列信息,能够更高效地捕捉时间序列信息,实现更准确的预测;Zhang等^[16]提出了一个基于图变换器的交通数据插补模型(GT-TDI),基于GPT和提示词工程技术,利用道路网络的时空语义理解来进行大规模交通数据补全。可见,大语言模型强大的语义嵌入能力可以将蕴含时空上下文的出行情景表征为语义向量,从而能够更高效地利用机器学习和深度学习模型对用户行为模式进行识别与预测。因此,本文旨在应用BERT大语言模型,将多维异构的时空特征嵌入统一的向量空间,实现对用户个性化出行情景的高效表征,进而输入多层感知器模型,将多模式出行方案的个性化推荐问题转化为一个多类别分类预测问题,实现个性化出行情景与多模式出行方案的精准匹配。

1 数据准备

1.1 数据描述与预处理

本文研究采用的数据来自百度地图提供的KDD Cup 2019竞赛第一阶段任务1的数据集,包括北京市部分用户的50万条历史出行数据,涵盖用户的出行查询记录、推荐记录、点击记录 and 用户

属性,具体信息如下:

(1)查询记录 记录了用户在百度地图中的一次路线搜索,每条记录包括用户ID、查询ID、查询时间,以及起点和终点的经纬度,如表1所示。

表1 查询记录数据样例

Tab. 1 Data sample of query records

查询ID	用户ID	查询时间	起点 经纬度/°	终点 经纬度/°
3 085 857 210 736		2018-11-16 10:53:10	116.39,39.84	116.33,39.79
559 931 202 427		2018-11-23 14:54:11	116.27,39.88	116.39,39.90
2 819 352 172 251		2018-10-30 11:48:41	116.34,39.96	116.37,39.86

(2)推荐记录 记录了在用户进行查询后,百度地图推荐的出行方案列表。每条记录包括查询ID、展示时间和出行方案集。出行方案集包含系统为每次查询所推荐的多个出行方案,每个方案包括交通方式编码(transport_mode)、距离(distance)、时间(eta)和费用(price)等信息,如表2所示。其中,交通方式包括6种单模式(公交、地铁、驾车、打车、步行、骑行)和5种多模式组合(如公交+地铁、地铁+打车等),通过1到11的数字编码不同交通方式。

(3)点击记录 记录了用户对显示记录的点击反馈,反映了用户最终选择的具体出行方案。每条记录包括点击时间和所选择的交通方式,如表3所示。

(4)用户属性 包含用户的性别、年龄、身高、职业等信息。为保护用户隐私,这些属性经过脱敏处理,并通过独热编码向量表示用户特征,而非直接提供用户的人口统计信息,如表4所示。

表2 推荐记录数据样例

Tab. 2 Data sample of recommendation records

查询ID	展示时间	出行方案集
3 085 857	2018-11-16 10:53:10	[{"distance": 13 864, "price": 600, "eta": 3 221, "transport_mode": 7}, {"distance": 11 106, "price": "", "eta": 1 122, "transport_mode": 3}, ..., {"distance": 11 243, "price": 300, "eta": 3578, "transport_mode": 1}]
559 931	2018-11-23 14:54:11	[{"distance": 14 735, "price": "", "eta": 1941, "transport_mode": 3}, {"distance": 14 735, "price": 3 100, "eta": 2061, "transport_mode": 4}, ..., {"distance": 13 640, "price": 300, "eta": 3982, "transport_mode": 1}]

表3 点击记录数据样例

Tab. 3 Data sample of click records

查询ID	点击时间	已选交通方式
3 085 857	2018-11-16 10:53:32	1 (bus)
559 931	2018-11-23 14:54:18	1 (bus)
2 819 352	2018-10-30 11:49:04	7 (bus+subway)

表4 用户属性数据说明

Tab. 4 Data description of user attribute


用户ID	p0	p1	...	p63	p64	p65
210 736	0	0	...	1	0	0
202 427	1	0	...	0	0	0
172 251	0	0	...	0	0	0
135 606	0	0	...	0	0	0

由于每次出行的查询ID是唯一的,可以通过该ID关联用户的查询记录、推荐记录与点击记录,从而构建出完整的用户出行数据。本文将查询时间作为用户的出行时间,并根据不同时间段将出行划分为高峰时段和平峰时段,以便分析高峰时段对出行行为的影响。具体而言,工作日(周一至周五)7:00~9:00为早高峰时段,17:00~19:00为晚高峰时段,其余时间段定义为平峰时段。此划分能够有效地揭示高峰时段和非高峰时段出行模式的差异。为了降低特征维度并增强时段的区分性,本文对出行时间段进行了独热编码。此外,用户ID可用于匹配用户的属性特征,从而获取用户属性数据。由于原数据集中的用户属性指标较多,且部分自变量之间存在较强的相关性,可能会影响模型的准确性,因此本文采用VIF(方差膨胀因子)多重共线性方法来筛选特征^[17]。通过剔除共线性较高的特征,最终保留了VIF值在5以内的42个属性指标。这样处理能够减少冗余信息,提高模型的预测精度。


1.2 数据特征分析

首先,本文对不同交通方式的时间分布进行了分析,结果如图1所示。无论是单模式交通还是多模式交通,几乎在每一个时间段,单模式出行的出行量都接近于多模式出行的两倍,这表明大多数用户仍然更习惯于传统的单模式出行。分析还显示,用户的出行活跃时段主要集中在8:00至18:00之间。从6:00至8:00,用户的整体活跃度逐渐上升,并在8:00至10:00之间快速攀升;而在18:00之后,出行活跃度开始下降,但即使在深夜

22:00至24:00,与凌晨相比仍有明显的出行活动。进一步观察发现,在出行活跃度高的时段,单模式交通方式中地铁、公交和步行尤其受欢迎,出行量较高;而在多模式交通方式中,用户更倾向于选择公交+地铁或地铁+驾车的组合方式。



(a) 单模式出行的出行时段分布




(b) 多模式出行的出行时段分布

图1 不同交通方式的出行时段分布


Fig. 1 Distribution of travel periods by mode of transport

接下来,分析不同交通方式的出行量与出行距离的关系,结果如图2所示。步行和骑行由于速度较慢,主要适用于5 km以内的短途出行;而公交和地铁则凭借价格和速度的优势,成为5 km以上出行的主要选择。自驾车和出租车虽然在速度上占优,但在高峰期容易受到拥堵影响,出行距离多集中在20 km以内。当行程距离超过20 km时,多模式出行方案则成为用户的首选,而在5 km以内,

用户几乎不会选择多模式出行。在20 km以内时,公交+地铁、地铁+驾车等组合交通方式颇受用户青睐;然而,随着出行距离超过20 km,由于私家车的费用问题,地铁+驾车的受欢迎程度逐渐下降。这些分析结果表明,单模式出行方案受制于速度和价格,通常更适合短距离出行;而多模式出行方案则在长距离出行中表现出更明显的速度和成本优势。



(a) 单模式出行的出行距离分布



(b) 多模式出行的出行距离分布

图2 不同交通方式的出行距离分布

Fig. 2 Distribution of travel distances by mode of transport

2 研究方法

用户可选择的出行方案集、出行时段以及用户属性的多样性共同构成了复杂的个性化出行情景。本文利用大语言模型中的语义嵌入技术,将多维异构的出行方案集转化为统一的向量表示,并与独热编码的出行时段向量以及用户属性向量

进行拼接,形成一个综合表征用户个性化出行情景的特征向量。通过这种方法,我们能够精准感知不同用户在不同时段、不同出行方案集下的个性化出行情景。随后,将个性化出行情景的综合特征向量输入到一个多层感知器模型中,以用户历史的出行方案选择为目标变量,从而构建一个能够精准预测用户偏好的多模式出行方案个性化推荐模型。上述分析框架如图3所述,下面将对其中的关键流程进行详细介绍。




图3 分析框架流程

Fig. 3 Flowchart of the analytical framework

2.1 基于BERT大语言模型的出行方案集语义嵌入

鉴于出行推荐系统每次规划的出行方案数量和显示顺序的差异,直接采用数值形式的特征表示出行方案集会导致特征维度不一致,难以直接作为机器学习模型的输入。例如,如表5所示,系统为查询1的用户推荐了两个出行方案,形成了一个 4×2 的矩阵;而为查询2的用户推荐了三个出行方案,形成了一个 4×3 的矩阵。为了解决这一问题,本文将推荐的出行方案集及其特征表示为文本格式,从而可以使用自然语言处理模型对文本进行表示学习,将出行方案集转化为固定长度的嵌入向量。这种处理方式,不仅充分捕捉了出行方案集中各方案的上下文关系,精确地刻画了出行特征,并有效地剔除了冗余信息。此外,这还便于将数据整合入模型进行训练,从而提高了对用户出行方案选择预测的准确性。

表5 出行方案集样例
Tab. 5 Sample of travel plans

查询ID	出行方案编号	出行距离/m	出行费用/分	出行时间/s	交通方式编码
1	①	27 279	800	5 528	7(bus+subway)
	②	26 468	700	6 601	1(bus)
2	①	40 265	3 000	4 274	2(subway)
	②	34 139	0	3 596	3(car)
	③	34 139	10 100	3 776	4(taxi)

BERT是一种基于Transformer架构的大语言模型,能够学习丰富的上下文信息,并更好地处理

词汇的多义性和复杂关系^[18],在数据向量编码任务中表现出良好性能。因此,本文选择BERT大语言模型来实现出行方案集的语义嵌入,如图4所示。基于BERT的出行方案集语义嵌入主要由以下三个部分组成:(1)出行方案集嵌入层,将文本形式的出行方案集分解为若干个token,并将这些token转换为固定维度的向量;(2)Transformer编码器,通过多层的Transformer结构,深入理解和学习出行方案集中各个出行方案的上下文语义信息,并对这些信息进行编码;(3)输出层,输出每次出行所规划的出行方案集嵌入向量,并确保所有嵌入向量的长度保持一致,以便后续在分类模型中使用。




图4 出行方案集语义嵌入

Fig. 4 Semantic embedding for travel plan sets

(1) 出行方案集嵌入层

本文将文本形式的出行方案集作为BERT大语言模型嵌入层的输入。首先,通过BERT的分词器将文本转化成一个一个token,并在每种出行方案的前后分别添加特殊的[CLS]和[SEP] token,[CLS]用于聚合整个出行方案的信息,[SEP]用于标记出行方案的结束,以此来区分各个出行方案。之后通过组合Token嵌入、Segment嵌入和Position嵌入,将所有的token转化为对应的向量表示。计算

公式为

$$E_{\text{Token}}(t) = W^M(W^T t) \quad (1)$$

$$E_{\text{Segment}}(t) = W^M(W^S t) \quad (2)$$

$$E_{\text{Position}}(t) = W^M(W^P t) \quad (3)$$

$$E_{\text{Input}} = E_{\text{Token}} + E_{\text{Segment}} + E_{\text{Position}} \quad (4)$$

式中: E_{Token} 代表每个token的语义信息向量; E_{Segment} 为帮助区分token属于哪个句子的向量,用于区分规划出的出行方案列表中不同出行方案; E_{Position} 表

示位置向量,编码序列中每个 token 的位置; E_{Input} 表示三种向量的叠加; W^M 是共享嵌入矩阵; W^T 、 W^S 、 W^P 分别是 Token 嵌入、Segment 嵌入和 Position 嵌入的可训练权重矩阵。

(2) Transformer 编码器

利用 Transformer 编码器对出行方案进行建模,学习和理解出行方案集中推荐的出行方案。具体来说,每个 Transformer 层中的自注意力机制通过计算序列中标记之间的关系来捕捉双向上下文。对于每个标记,嵌入被投影为三个向量:查询向量 Q 、键向量 K 和值向量 V 。自注意力函数的公式为

$$\text{Attn}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (5)$$

式中: d_k 表示键向量的维度; K^T 表示键向量的转置。

多头注意力机制应用了多个独立的注意力机制,并将它们的输出连接起来,计算公式为

$$\text{Head}_i = \text{Attn}(QW_i^Q, KW_i^K, VW_i^V)\theta \quad (6)$$

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{Head}_1, \dots, \text{Head}_h)W^O \quad (7)$$

式中: Head_i 是第 i 个头用向量表示的自注意力; W_i^Q 、 W_i^K 和 W_i^V 是第 i 个头学习到的权重矩阵; W^O 是输出权重矩阵; h 是头部的数量。

应用层归一化方案和前馈网络以产生第 l 层的隐藏向量,计算公式为

$$\text{ln}_l = \text{LayerNorm}(\text{FC}(\text{attn}_l) + Z_{l-1}) \quad (8)$$

$$Z_l = \text{FC}(\text{Gelu}(\text{FC}(\text{ln}_l))) \quad (9)$$

式中: l 是 Transformer 编码层的索引; ln_l 是层归一化后的向量; attn_l 是 l 层的注意力输出向量; Z_l 是第 l 层的输出向量; FC 是用于实现前馈网络以转换其输入数据的全连接层; Gelu 是激活函数。最后一个 Transformer 编码层的输出 Z_L 是 Transformer 编码器学习到的表示向量。

(3) 输出层

由于直接输出出行方案集的嵌入向量,其长度可能不一致,因此在输出层中添加了一个池化层。该池化层在保留出行方案集全局时空依赖性的同时,对生成的表征向量进行平均池化,最终生成统一长度的 384 维嵌入向量,用于综合表示出行方案集。

通过 BERT 大语言模型,可以提取出行方案集的语义向量表示。随后,将该语义向量与用户属性特征的独热编码及出行时段的独热编码进行拼接,形成包含个性化出行情景特征的完整语义表示,从而构建个性化出行方案推荐所需的全局出行情景向量。计算公式为

$$E_{\text{Contexts}} = E_{\text{Outputs}} \oplus E_{\text{Time}} \oplus E_{\text{Attributes}} \quad (10)$$

式中: E_{Contexts} 是拼接后的出行情景嵌入向量; E_{Outputs} 是 BERT 大语言模型输出的出行方案集语义向量; E_{Time} 是独热编码后的出行时段向量; $E_{\text{Attributes}}$ 是独热编码后的用户属性向量。

如表 6 所示,个性化出行情景向量的构建整合了出行方案集的语义信息、出行时段特性和用户属性特征,使推荐模型具备感知不同用户个性化出行情景的能力,从而有效提升出行方案推荐的准确性和用户满意度。

表 6 个性化出行情景嵌入向量样例

Tab. 6 Sample personalized travel scenario characteristics

用户 ID	查询 ID	出行方案集			出行时段			用户属性		
		<i>embedding</i> 1	...	<i>embedding</i> 384	早高峰	晚高峰	平峰	<i>p</i> 9	...	<i>p</i> 65
33 264	12 154	0.013 2	...	-0.007 5	1	0	0	1	...	0
33 264	23 345	0.019 8	...	0.014 9	0	1	0	0	...	0
12 126	13 154	-0.016 7	...	0.005 3	0	0	1	0	...	1

2.2 基于多层感知器的多模式出行方案个性化推荐

多模式出行方案个性化推荐旨在根据不同用户、不同时段、不同可选择的出行方案集(包含不同出行方式的出行距离、费用、时间),预测用户最有可能选择的出行方案,并将所有出行方案按选择概率排序。因此,出行方案的个性化推荐模型本质上是一个多类别分类任务,其输入为上述基于大语言

模型生成的个性化出行情景嵌入向量,输出为百度地图出行数据集中涉及的 11 种出行方式。

多层感知器是一种由一个输入层、若干隐藏层以及一个输出层构成的经典神经网络模型,输入层的神经元数量与数据集的特征数量直接相关,而隐藏层的数量和每层的神经元数量则根据特定的问题需求来设定^[19]。每个神经元与下一层

中的所有神经元通过权重连接,并附带一个偏差值,这种结构支持网络捕捉数据中的复杂模式^[20]。由于MLP模型结构灵活,可以有效处理大规模和高维度的特征数据集^[21],特别适合处理复杂的机器学习任务,如多分类、点击率预估和搜索排序等^[22]。因此,本文采用MLP构建多模式出行方案个性化推荐模型。

在MLP的运行过程中,首先通过前向传播算法从输入层到输出层逐层计算神经元的输出,在第一层计算之前,将上述基于BERT大语言模型得到的个性化出行情景嵌入向量 $\mathbf{E}_{\text{Contexts}}$ 作为首层神经元处理的特征输入,然后根据输出层的结果与实际目标值之间的差异计算损失值,并根据更新权重和偏差进行优化^[23]。计算公式为

$$\mathbf{a}^{(l+1)} = f(\mathbf{W}^{(l)}\mathbf{a}^{(l)} + \mathbf{b}^{(l)}) \quad (11)$$

$$\mathbf{a}^{(1)} = f(\mathbf{W}^{(1)}\mathbf{E}_{\text{Contexts}} + \mathbf{b}^{(1)}) \quad (12)$$

$$\mathbf{W}^{(l)} = \mathbf{W}^{(l)} - \eta \frac{\partial L}{\partial \mathbf{W}^{(l)}} \quad \mathbf{b}^{(l)} = \mathbf{b}^{(l)} - \eta \frac{\partial L}{\partial \mathbf{b}^{(l)}} \quad (13)$$

式中: $\mathbf{a}^{(l)}$ 是第 l 层的输出向量; $\mathbf{W}^{(l)}$ 是从层 l 到层 $l+1$ 的权重矩阵; $\mathbf{b}^{(l)}$ 是层 l 的偏差向量; f 代表激活函数; L 是损失函数,表示当前模型参数下的误差或性能; η 是学习率,决定了学习步长的超参数。

具体到每一层,神经网络的操作可以表示为一个复杂的函数映射,其中包括权重的线性组合加上偏差,再通过激活函数进行非线性转换。本文构建了一个包含两个隐藏层的MLP模型,模型使用ReLU作为隐藏层的激活函数,并采用Adam优化算法进行训练,这种算法结合了梯度下降的多种优化技术,能有效处理非凸优化问题,帮助解决梯度消失问题并保持计算的稳定性。损失函数选择多分类任务常用交叉熵损失。输出层的激活函数则使用多分类问题通常使用softmax函数。

3 结果与评估

在实验设计方面,本文将出行数据集按照7:2:1的比例随机划分为训练集、验证集和测试集,其中训练集用于模型训练,验证集用于超参数调优和模型选择,测试集用于最终性能评估。输入特征为出行的个性化出行情景向量,目标变量为用户的出行方案选择,采用多层感知器(MLP)模型进行多模式出行方案的个性化推荐。为了全面评估MLP的效能,本研究将其与其他几种常用的机器学习模型进行比较,包括K近邻(KNN)、随机森林

(RF)、逻辑回归(LR)、朴素贝叶斯(NB)和支持向量机(SVM)。鉴于数据集存在样本类别不平衡的问题,为了更有效地衡量模型的性能并确保模型同时具备较高的精确率与召回率,本研究采用加权F1分数作为评估不平衡学习性能的指标,具体计算方式如公式(14)和(15)所示。

$$F_{1, \text{Class}_i} = \frac{2 \text{precision} \times \text{recall}}{\text{precision} + \text{recall}} \quad (14)$$

$$F_{1, \text{weighted}} = \sum_{i=1}^k w_i F_{1, \text{Class}_i} \quad (15)$$

式中: precision 表示样本类别 i 的预测精度; recall 表示样本类别 i 的召回率; w_i 表示样本类别 i 的权重;加权的F1分数 $F_{1, \text{weighted}}$ 通过各个类别的F1分数 F_{1, Class_i} 加权得到。

各模型在测试集上的性能评价结果如图5所示,MLP模型的加权F1分数最高,达到0.709,并且在准确率、精确率和召回率等多个性能指标上也展现出了较为优越的表现,超越了传统机器学习模型。这一结果表明,MLP因其能够有效处理高维度和非线性的数据特征,在多模式出行方案个性化推荐任务中表现出较高的适应性和准确性。因此,使用经过训练的MLP模型来为用户提供定制化的出行方案推荐,可以优化用户的出行体验和效率。




图5 模型性能比较

Fig. 5 Model performance comparison

为了进一步验证出行时段和用户属性对出行方案个性化推荐的作用,本文还分别训练了2个模型:①仅输入出行方案集特征向量的MLP模型;②输入出行方案集、出行时段、用户画像综合特征向量的MLP模型(即上文构建的个性化出行情景嵌入向量)。两个模型在测试集上的各项评估指标对比如表7所示。

表 7 模型评估指标对比
Tab. 7 Comparison of model evaluation indexes

交通方式	模型①			模型②			支持度	样本比例/%
	精 度	召回率	加权 F1 分数	精 度	召回率	加权 F1 分数		
公交	0.57	0.70	0.63	0.65	0.71	0.68	9 796	16.04
地铁	0.85	0.73	0.79	0.86	0.96	0.91	19 254	31.22
驾车	0.58	0.01	0.02	0.61	0.02	0.04	2 644	4.4
打车	0.56	<0.01	0.01	0.57	<0.01	0.01	1 553	2.55
步行	0.79	0.91	0.85	0.84	0.91	0.87	5 999	9.74
骑行	<0.01	<0.01	<0.01	0.37	<0.01	0.01	1 548	2.47
公交+地铁	0.64	0.90	0.75	0.75	0.91	0.82	11 271	18.18
公交+打车	0.50	0.01	0.02	0.51	0.02	0.04	205	0.38
地铁+驾车	0.52	0.64	0.57	0.52	0.65	0.58	6 783	10.7
地铁+打车	0.41	0.21	0.28	0.46	0.25	0.32	1 810	2.98
地铁+骑行	0.54	0.47	0.50	0.55	0.59	0.57	839	1.34
Macro average	0.542	0.417	0.402	0.608	0.457	0.441		
Weighted average	0.667	0.674	0.644	0.720	0.754	0.709		

经过对比模型①和模型②的评估指标可以发现,在考虑用户个性化出行情景后,推荐系统的精确率、召回率、加权 F1 分数均显著提升。具体来看,推荐系统对于骑行、公交+地铁、公交、步行以及地铁+打车的预测精确率分别提高了 0.37、0.11、0.08、0.05、0.05,说明对于这几类出行方式的个性化推荐更容易得到用户的点击选择。同时,从支持度和样本比例的角度来看,支持度较大的类别(如地铁和公交+地铁)在推荐系统的优化中受益更多。对于倾向于使用地铁和地铁+骑行的用户群体,推荐系统的预测召回率分别提高了 0.23 和 0.12,即出行方案个性化推荐的匹配度提高 23% 和 12%,反映出这两类用户群体对个性化出行情景特征具有更高的敏感性。相比之下,地铁、地铁+驾车、驾车以及打车等用户群体则对情景特征表现

出较低的敏感性,其精度和召回率均未发生显著变化。对比分析不同用户群体对情景特征的敏感性,为提高出行方案推荐系统的个性化程度提供了有价值的方向。

同时,为了进一步证明 BERT 大语言模型对个性化出行情景的感知能力,本文还分析了不使用 BERT 模型对出行方案集进行语义嵌入,而是将出行方案集中离散的交通方式特征、用户属性和出行时段特征直接输入 MLP 模型的结果,如表 8 所示。通过对比可以发现,使用 BERT 模型对出行方案集进行语义嵌入,推荐性能得到了显著提升,加权 F1 分数从 0.369 提高到 0.709。此外,将已有研究中其他模型纳入对比分析,使用相同数据集得到评估指标如表 8 所示。

表 8 模型对比
Tab. 8 Models comparison

作 者	特征工程	预测模型	精 度	召回率	加权 F1 分数
本研究	BERT 语义嵌入	MLP	0.720	0.754	0.709
	无嵌入	MLP	0.369	0.499	0.369
Abedalla 等 ^[24]	无嵌入	CNN+XGBoost	/	/	0.689
Zhu 等 ^[25]	无嵌入	SMOTE+LightGBM	0.537	0.507	0.695
Liu 等 ^[26]	二部图嵌入	LightGBM+后处理	/	/	0.690
孙全能等 ^[12]	Node2Vec 图嵌入	CaGBDT	/	/	0.695

(1)Abedalla 等^[24]提取了出行方案集中各交通方式的时间、距离、费用的最大值和最小值以及用户所选择交通方式的特征,并结合出行当日的天气特征和用户属性特征,将这些统计特征直接输入到 CNN 和 XGBoost 的集成模型中进行训练。

(2)Zhu 等^[25]基于出行时段、出行方案集中各交通方式特征的描述性统计、起点和终点附近的 POI 以及用户属性等构成 304 维的特征向量,并采用 SMOTE 方法对数据进行过采样,然后将这些高维特征直接输入到 LightGBM 模型中进行训练。

(3)Liu等^[26]综合考虑了交通方式、用户以及空间相关特征,同时还构建了表示用户-OD对的二部图,并利用图嵌入技术将图中的节点转换为特征向量,随后将所有特征向量融合后输入到LightGBM模型中进行训练。此外,还设计了一种后处理算法,通过随机扰动矩阵来获取调整系数,用于微调模型的预测结果,以提高模型的准确性。

(4)孙全明等^[12]利用Node2Vec图嵌入模型对构建的OD关系图进行表征学习,并将图嵌入向量与出行方案集特征、时间特征、空间特征、POI特征以及用户属性特征拼接,输入到由LightGBM和XGBoost级联的CaGBDT模型中进行训练。

综上所述,已有同类研究主要是基于多维度的显性特征,训练集成学习模型对用户选择的出行方式进行预测,但难以有效地捕获各种特征之间的时空依赖性,如出行时间的周期性、出行空间的连续性以及出行方式的相关性。相比之下,BERT等大规模预训练模型凭借其强大的语义嵌入能力,能够更精准地感知用户个性化出行情景中的差异化出行需求与复杂时空上下文关系。因此,本文通过BERT大语言模型将多维异构的个性化出行情景嵌入统一的向量空间,不仅显著提升了推荐系统的性能,也为个性化出行方案的推荐提供了新的技术手段和突破方向。

4 结论

本文提出了一种基于大语言模型的多模式出行方案个性化推荐算法,能够根据用户的差异化出行情景,为其提供更贴合需求的出行方案推荐。首先,从百度地图历史出行大数据中提取用户出行规划、查询、选择的行为数据以及用户属性数据;接着,使用BERT大语言模型,将推荐出行方案集的文本化描述特征嵌入到连续向量空间中,并与出行时段和用户属性特征进行融合得到综合表征用户个性化出行情景的特征向量;随后将个性化出行情景向量输入MLP模型,以预测用户的个性化出行方案选择。基于北京市50万次实际出行规划数据对模型进行训练、测试与评价,得到以下主要结论:

(1)BERT大语言模型能够有效将多维异构的出行方案集文本描述数据嵌入统一的向量空间,从而更有效地表征学习多维异构的输入特征,为出行方案个性化推荐模型提供更丰富的输入信息。

(2)MLP模型在用户出行方案预测上的准确

率、精确率、召回率以及加权F1分数均优于KNN、RF、LR、NB和SVM等传统机器学习模型,表明MLP模型在多模式出行方案个性化推荐中具有较高的适应性。

(3)用户的出行方案选择不仅与出行方案集本身的特征有关,还受出行时段、用户属性等特征的影响,因此考虑用户个性化出行情景可以显著提升推荐系统的满意度,其中使用地铁和地铁+骑行的用户群体对于个性化推荐较为敏感,而使用地铁、地铁+驾车、驾车以及打车等用户群体则较不敏感。

(4)与已有研究中使用相同数据集的其他模型相比,本文基于BERT语义嵌入与MLP构建的多模式出行方案个性化推荐模型,能够更精准地捕捉个性化出行情景中蕴含的深层次语义关系,因此推荐性能仍然保持最优。

尽管本文提出的用户多模式出行方案个性化推荐方法在准确性上取得了显著成效,但由于样本不均衡问题,部分交通方式的样本量较低,导致预测精度有所下降。未来研究中,可以考虑采用样本量更大且交通方式类别分布更均匀的数据集,以实现更细致的出行方案推荐。此外,本文的算法可嵌入到实际的出行规划与导航应用中,为用户提供更加个性化的出行服务与更高质量的出行体验。

参考文献

- [1] 孙全明, 曲志坚, 任崇广. 基于粒子群优化和LightGBM的情景感知多式联运推荐[J]. 电子学报, 2021, 49(5): 894-903.
SUN Quanming, QU Zhijian, REN Chongguang. Context-aware multi-modal transportation recommendation based on particle swarm optimization and LightGBM[J]. Acta Electronica Sinica, 2021, 49(5): 894-903.
- [2] HUANG Y Q, GAO L J, NI A N, et al. Analysis of travel mode choice and trip chain pattern relationships based on multi-day GPS data: a case study in Shanghai, China[J]. Journal of Transport Geography, 2021, 93: 103070.
- [3] LIU L, XU J, LIAO S S, et al. A real-time personalized route recommendation system for self-drive tourists based on vehicle to vehicle communication[J]. Expert Systems with Applications, 2014, 41(7): 3409-3417.
- [4] HERZOG D, MASSOUD H, WÖRNDL W. RouteMe: a mobile recommender system for personalized, multi-modal route planning[C]//Proceedings of the 25th Conference on User Modeling, Adaptation and Personalization. Bratislava Slovakia: ACM, 2017: 67-75.
- [5] DU R, ZHANG N, GAO X, et al. Optimal path choice

- based on multi-modal public transport—a case study of the Chengdu Qinghua Road area[C]//ICTE 2015. Dailan: American Society of Civil Engineers, 2015: 1682-1688.
- [6] SOCHAROENTUM M, KARIMI H A. Multi-modal transportation with multi-criteria walking (MMT-MCW): personalized route recommender[J]. *Computers, Environment and Urban Systems*, 2016, 55: 44-54.
- [7] DAI J, YANG B, GUO C, et al. Personalized route recommendation using big trajectory data[C]//2015 IEEE 31st International Conference on Data Engineering. Seoul, Korea (South): IEEE, 2015: 543-554.
- [8] 段宗涛, 任国亮, 康军, 等. 基于频繁轨迹序列模式挖掘的路径推荐方法[J]. *太原理工大学学报*, 2022, 53(2): 240-247.
- DUAN Zongtao, REN Guoliang, KANG Jun, et al. Route recommendation method based on frequent trajectory sequence pattern mining[J]. *Journal of Taiyuan University of Technology*, 2022, 53(2): 240-247.
- [9] CHEN Z B, SHEN H T, ZHOU X F. Discovering popular routes from trajectories[C]//2011 IEEE 27th International Conference on Data Engineering. Hannover, Germany: IEEE, 2011: 900-911.
- [10] LIU H, LI T, HU R J, et al. Joint representation learning for multi-modal transportation recommendation[J]. *Proceedings of the AAAI Conference on Artificial Intelligence*, 2019, 33(1): 1036-1043.
- [11] WU F, LYU C, LIU Y. A personalized recommendation system for multi-modal transportation systems[J]. *Multi-modal Transportation*, 2022, 1(2): 100016.
- [12] 孙全明, 常磊, 马铨, 等. 基于图嵌入和CaGBDT的多模式出行推荐[J]. *北京邮电大学学报*, 2021, 44(5): 81-87, 106.
- SUN Quanming, CHANG Lei, MA Cheng, et al. Multi-modal transportation recommendation based on graph embedding and CaGBDT[J]. *Journal of Beijing University of Posts and Telecommunications*, 2021, 44(5): 81-87, 106.
- [13] LI W X, ZHANG Y L, CHEN Y F, et al. Multi-day activity pattern recognition based on semantic embeddings of activity chains[J]. *Travel Behaviour and Society*, 2024, 34: 100682.
- [14] 贺正冰. 大语言模型在道路交通领域应用: 创新与挑战[J/OL]. *交通运输工程与信息学报*, 1-10(2024-12-11)[2024-12-11]. <https://doi.org/10.19961/j.cnki.1672-4747.2024.12.001>.
- HE Zhengbing. Large language models in road transportation: innovations and challenges [J/OL]. *Journal of Transportation Engineering and Information*, 1-10(2024-12-11) [2024-12-11]. <https://doi.org/10.19961/j.cnki.1672-4747.2024.12.001>.
- [15] JIN K, WI J, LEE E, et al. TrafficBERT: Pre-trained model with large-scale data for long-range traffic flow forecasting[J]. *Expert Systems with Applications*, 2021, 186: 115738.
- [16] ZHANG K P, ZHOU F, WU L, et al. Semantic understanding and prompt engineering for large-scale traffic data imputation[J]. *Information Fusion*, 2024, 102: 102038.
- [17] URAIBI H S. VIF-regression screening ultrahigh dimensional feature space[J]. *Journal of Modern Applied Statistical Methods*, 2021, 19(1): 3.
- [18] DEVLIN J, CHANG M W, LEE K, et al. BERT: pre-training of deep bidirectional transformers for language understanding[EB/OL]. arXiv, 2018:1810.04805. <https://arxiv.org/abs/1810.04805v2>.
- [19] CAR Z, ŠEGOTA S B, ANĐELIĆ N, et al. Modeling the spread of COVID-19 infection using a multilayer perceptron[J]. *Computational and Mathematical Methods in Medicine*, 2020, 2020: 5714714.
- [20] AYDIN Y, CAKIROGLU C, BEKDAŞ G, et al. Explainable ensemble learning and multilayer perceptron modeling for compressive strength prediction of ultra-high-performance concrete[J]. *Biomimetics*, 2024, 9(9): 544.
- [21] AL BATAINEH A, MANACEK S. MLP-PSO hybrid algorithm for heart disease prediction[J]. *Journal of Personalized Medicine*, 2022, 12(8): 1208.
- [22] HEIDARI A A, FARIS H, ALJARAHI I, et al. An efficient hybrid multilayer perceptron neural network with grasshopper optimization[J]. *Soft Computing*, 2019, 23: 7941-7958.
- [23] GÉRON A. Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow(2nd Edition)[M]. O'Reilly, 2022.
- [24] ABEDALLA A, FADEL A, TUFFAHA I, et al. MTRecS-DLT: multi-modal transport recommender system using deep learning and tree models[C]//2019 Sixth International Conference on Social Networks Analysis, Management and Security (SNAMS). Granada, Spain: IEEE, 2019: 274-278.
- [25] ZHU M, HU J, Hao, et al. Personalized context-aware multi-modal transportation recommendation [EB/OL]. arXiv, 2019: 1910.12601. <https://arxiv.org/abs/1910.12601v1>.
- [26] LIU Y, LYU C, LIU Z Y, et al. Exploring a large-scale multi-modal transportation recommendation system[J]. *Transportation Research Part C: Emerging Technologies*, 2021, 126: 103070.

(责任编辑: 项吕)