

文章编号:1671-1637(2023)05-0253-11

面向个体出行推荐的联邦异质性模型和算法

由林麟¹, 贺俊姝¹, 陈坤旭¹, 何家琪¹, 袁绍欣², 赵娟娟³, 蔡 铭¹

(1. 中山大学 智能工程学院, 广东 深圳 518107; 2. 长安大学 信息工程学院, 陕西 西安 710064;
3. 首都师范大学 资源环境与旅游学院, 北京 100048)

摘 要:为实现兼顾偏好异质性与数据隐私化的个体出行推荐,基于模型参数化聚合与分布式训练的联邦学习计算范式,提出了一种联邦混合罗吉特(FMXL)模型,可解构标准 MXL 模型,以实现本地个体偏好与全局群体差异参数估算的分离;为了消除模型对原始数据的依赖,提出了标准与聚合 2 种联邦吉布斯抽样算法,通过本地与全局参数的交互,实现模型的层次化联合估计;为了验证所提模型与算法,基于 Swiss Metro 公开数据集,分别搭建了离线与在线 2 种出行推荐场景。分析结果表明:针对离线场景,2 种联邦吉布斯抽样算法拟合的 FMXL 模型与标准多项式罗吉特模型相比,其对数似然值分别增大了 157.8 和 153.2,预测率分别提升了 12.3%和 12.1%;与基于集中式吉布斯抽样算法拟合的 MXL 模型相比,其计算时间分别缩短了 64.2%和 76.9%,通信时间均缩短了 86.2%;针对在线场景,FMXL 模型的对数似然值和预测率均呈上升趋势,且整个估计过程的计算和通信时间均低于标准 MXL 模型。可见,以数据隐私化处理为前提,MXL 模型的联邦化训练既能保证出行推荐的精准性,也能充分调动用户端闲置算力,有效提升出行推荐的时效性,体现了所提模型和算法的高适应和可拓展能力,同时基于联邦异质性模型的个体出行推荐还能有效推进交通系统的智能化进程。

关键词:智能交通;出行推荐;联邦学习;混合罗吉特模型;隐私保护;个性化

中图分类号:U491.1 **文献标志码:**A **DOI:**10.19818/j.cnki.1671-1637.2023.05.018

Federated heterogeneous model and algorithm for personal travel recommendation

YOU Lin-lin¹, HE Jun-shu¹, CHEN Kun-xu¹, HE Jia-qi¹, YUAN Shao-xin²,
ZHAO Juan-juan³, CAI Ming¹

(1. School of Intelligent Systems Engineering, Sun Yat-Sen University, Shenzhen 518107, Guangdong, China;
2. School of Information Engineering, Chang'an University, Xi'an 710064, Shaanxi, China; 3. College of
Resource Environment and Tourism, Capital Normal University, Beijing 100048, China)

Abstract: To achieve personal travel recommendations by considering both the preference heterogeneity and data privacy, based on the model parametric aggregation and distributed training supported by the federated learning (FL) computing paradigm, a federated mixed Logit (FMXL) model was proposed by decoupling the standard mixed Logit model to separate the parameter

收稿日期:2023-03-27

基金项目:国家自然科学基金项目(62002398,41901188);国家重点研发计划(2020YFB1600400);广东省基础与应用基础研究基金项目(2023A1515012895);广州市科技计划项目(202206010056)

作者简介:由林麟(1987-),男,辽宁丹东人,中山大学副教授,工学博士,从事智能交通系统研究。

通讯作者:赵娟娟(1988-),女,河南焦作人,首都师范大学讲师,工学博士。

引用格式:由林麟,贺俊姝,陈坤旭,等.面向个体出行推荐的联邦异质性模型和算法[J].交通运输工程学报,2023,23(5):253-263.

Citation: YOU Lin-lin, HE Jun-shu, CHEN Kun-xu, et al. Federated heterogeneous model and algorithm for personal travel recommendation[J]. Journal of Traffic and Transportation Engineering, 2023, 23(5): 253-263.

estimation of local individual preferences and global population differences. In order to eliminate the dependence of the model on the original data, two federated Gibbs sampling algorithms, to be standardized or aggregated, were designed, to achieve the hierarchical estimation of the model through the interaction of local and global parameters. The proposed model and algorithm were validated for offline and online travel recommendation scenarios based on Swiss Metro data. Analysis results show that for offline scenario, the FMXL model based on two federated Gibbs sampling algorithms increase the log-likelihood value by 157.8 and 153.2, and the prediction rate by 12.3% and 12.1%, respectively, compared with the standard multinomial Logit model. In addition, the computation time reduce by 64.2% and 76.9%, respectively, and the communication times both reduce by 86.2% compared with the mixed Logit model based on the centralized Gibbs sampling algorithm. For the online scenario, both the log-likelihood value and the prediction rate of the FMXL model show an increasing trend, and the computation and communication times of the whole estimation process are lower than those of the standard mixed Logit model. Overall, with the data privacy as the precondition, the federated training of the MXL model ensures the accuracy of travel recommendations and effectively enhances the timeliness of travel recommendations by fully utilizing the idle computing power on the user side, reflecting the high adaptability and scalability of the proposed model and algorithms. In addition, the intelligent progress of the transportation system can be promoted effectively by personal travel recommendations based on the FMXL model. 3 tabs, 4 figs, 30 refs.

Key words: intelligent transportation; travel recommendation; federated learning; mixed logit model; privacy protection; personalization

Author resumes: YOU Lin-lin(1987-), male, associate professor, PhD, youllin@mail.sysu.edu.cn; ZHAO Juan-juan(1988-), female, assistant professor, PhD, zhao@cnu.edu.cn.

Foundation items: National Natural Science Foundation of China (62002398, 41901188); National Key Research and Development Program of China (2020YFB1600400); Guangdong Basic and Applied Basic Research Foundation (2023A1515012895); Science and Technology Planning Project of Guangzhou (202206010056)

0 引 言

随着交通基础设施和出行工具的快速革新,出行模式正在不断演变,与此同时,人们日益增长的出行需求也使个体出行行为更具多样性^[1]。面向新形势,出行推荐^[2]作为一种提升交通系统智能化水平的重要手段,成为近年来的研究热点,它可以通过识别用户出发地和目的地,对出行方案进行智能化推荐,帮助用户快速获取所需要的出行信息,有效提升个体出行体验^[3]。

尽管当前基于内容、协同过滤、混合系统的推荐方法可达到较高推荐精度,但普遍易导致推荐的同质化,即根据用户群的行为特征及潜在关联性进行方案推荐,难以有效保证出行推荐的个体满意度^[4]。具体而言,现有研究在数据上大多依托于出行轨迹、社交定位、服务记录等多源异构个

体级数据,在方法上多采用集中式机器学习技术,可从宏观上挖掘符合大众认知的群体潜在出行规律,并通过聚类、矩阵分解等手段实现出行方案的智能化推荐。Cui等^[5]基于用户历史GPS轨迹,通过协同过滤方法聚合具有相似行为的用户,估计用户出行频率,采用朴素贝叶斯模型推荐出行路线;Wen等^[6]利用社交媒体上用户照片和签到记录中所附带的GPS数据,挖掘社交信息和兴趣点特征,设计了一种基于用户偏好的出行推荐方法;孙全明等^[7]基于百度地图的查询、展示、点击记录以及用户属性数据,通过提取用户出行潜在的时空信息,构建了级联梯度提升决策树,实现多模态出行方案的推荐;杨敏等^[8]基于票务订单数据,使用TF-IDF文本挖掘算法、K-Means聚类算法构建旅客出行画像,并依据偏好得分、敏感特征设置奖励函数,使用强化学习算法实现公铁联程出行方

案的推荐。

为弥补现有研究对个体偏好表征能力的不足,基于混合罗吉特(Mixed Logit, MXL)模型的个体出行推荐方法得到了学者的关注^[9]。总的来说, MXL 模型作为一种离散选择模型,可通过参数设置对用户出行选择行为的异质性进行建模,从根本上解决推荐同质化问题。它将用户特征、方案属性、上下文信息等多种推荐属性整合为一个效用函数,根据历史出行选择,将属性参数拟合随机参数,依靠随机参数的标准差探究个体偏好差异,进而开展个体层面的出行偏好估计,并据此对方案进行排序推荐。相关研究表明,影响个体行为异质性的因素通常来源于自身^[10],因此,基于 MXL 模型的出行推荐需要纳入更多包含个体经济社会属性的数据,如年龄、性别、职业、收入、受教育水平等。然而,上述数据普遍涉及个人隐私,如将此类数据以集中式的方法直接共享至云端实现模型参数的估计,会存在隐私泄露的风险。与此同时,随着数据隐私保护日渐受到人们的重视,如《国家安全法》《通用数据保护条例》^[11]等法律条例的出台与实施,将进一步制约上述研究的实际应用。

为实现 MXL 模型的隐私化训练,可以借鉴联邦学习这一新兴的计算范式^[12]。总的来说,联邦学习可以依托设备端(如智能手机)的计算能力,隐私化协同多方数据,共同训练全局模型,以实现与集中式方法相当的建模效果。在整个交互过程中,任何一方只需上传模型参数(无需透露原始数据),继而通过参数聚合得到全局模型,因此,联邦学习可有效降低隐私泄露风险^[13],并提高设备端的利用率^[14]。

现阶段联邦学习多面向机器学习模型,如支持向量机^[15]、决策树^[16]、神经网络^[17],因上述模型的求解均可基于梯度下降法完成,故联邦训练过程具备一定的通用性,即与模型无关。例如横向联邦训练^[12],首先,参与方在各自的设备端根据目标模型,使用本地数据(建模所需的私有原始数据)获得本地模型参数;随后,协调方(通常为中央服务器)基于各方上传的本地模型参数,通过聚合算法(如联邦平均算法^[18])更新和广播全局模型,并开启新一轮迭代,直至全局模型收敛。然而,作为一种统计模型, MXL 模型需要对复杂分布和高维数值进行估算,无法直接应用基于梯度的联邦训练过程^[12],实现本地与全局训练的协同,因此,需要针对 MXL 模型定义本地与全局协作训练流程以及协同求解算法,实现联邦学习与 MXL 模型的深度融合。

综上,本文面向个体出行服务,以实现用户隐私数据保护、出行体验增强为目标,提出融合联邦学习和 MXL 模型的联邦 MXL 模型,并设计相应求解算法,可在充分调动用户端闲置算力和缩短推荐响应时间的同时,实现个体行为异质化与数据隐私化的个体出行推荐。

总的来说,本文有如下 3 点创新。

(1)定义面向个体出行隐私化推荐的联邦学习问题及模型,在保证用户隐私的前提下,基于本地数据,协同构建具备个体异质性的本地化模型,实现出行的个性化推荐。

(2)设计标准吉布斯抽样算法^[19],通过协同模拟模型的后验分布,对模型参数进行隐私化估计。

(3)设计聚合吉布斯抽样算法,通过设置模型的聚合机制,在保证模型参数隐私化估计的同时,进一步提高模型训练效率。

1 问题描述

假设 B 为用户集合,其中 $B = \{1, \dots, n, \dots, N\}$; C_n 为对于用户 n 可推荐的出行方案集合, $C_n = \{1, \dots, j, \dots, J\}$; j_n^* 为用户 n 取得最大效用值的方案; $U(n, j)$ 为效用函数,用于计算用户 n 对方案 j 的偏好。出行推荐的目标在于找到使效用函数 $U(n, j)$ 取得最大值的方案^[20],即

$$j_n^* = \operatorname{argmax}_{j \in C_n} [U(n, j)] \quad (1)$$

本文将面向如上出行推荐场景,采用 MXL 模型标定效用函数,同时,为克服集中式建模带来的隐私安全问题,提出面向联邦学习的模型求解算法。

为实现以上目标,定义本文的研究问题为个体出行方案隐私化推荐的联邦学习问题:给定用户集合 B ,每位用户 $n \in B$ 具有一定的计算和通信能力,并保留用户 n 与历史出行选择记录相关的数据 D_n ,即本地数据。如图 1 所示,中央服务器协调各用户,构建面向用户 n 的本地化离散选择模型 M_n ,即本地模型,结合用户模型得到对应的训练指令,再将其分发到不同用户。训练要同时满足以下 3 个条件。

(1)隐私性:作为训练的重要前提,各用户端不共享原始数据,仅与中心服务器通信交换本地模型 M_n 或由中心服务器聚合用户模型得到的训练指令 $O(M_1, \dots, M_N)$ 。

(2)协同性:模型的训练过程在用户边缘端与服务云端同时协作运行,可提高本地资源的利用率,降低中央服务器的负载。




图1 个体出行隐私化推荐的联邦学习

Fig. 1 Federated learning for personal travel privacy recommendation

(3) 异质性: 训练得到的本地模型 M_n 能够表征个体层面的偏好, 即各本地模型之间存在差异。

综上, 面向研究问题中用户数据隐私保护、个体资源协同和异质特征表征的三方面挑战, 本文章节安排如下: 第2节定义联邦混合罗吉特(Federated Mixed Logit, FMXL)模型; 第3节对模型的联邦求解过程和算法进行介绍; 第4节对所提模型和算法进行有效性验证; 第5节为结论与未来工作展望。

2 FMXL 模型

MXL 模型因能获取选择偏好异质性, 逐渐被应用于个体出行方案推荐中^[21]。标准 MXL 模型把参数设定为服从一定分布的随机变量, 通过随机变量的标准差反映群体中的偏好异质性。而在贝叶斯观点下, 标准 MXL 模型实际上是一种双层多项式 Logit 模型, 可以通过先验-群体层和群体-个体层获取个体的偏好^[22]。基于贝叶斯思想, 本文提出了 FMXL 模型, 如图2所示, 该模型分为本地模型与全局分布2个部分, 并通过贝叶斯估计方法对模型参数进行估计, 所得到的联邦模型与集中式标准模型有相同效果。对于本地模型: 定义用户 n 对应的选择数据为 d_n , 函数 $U_{n,j}$ 为捕获每个用户 $n \in B$ 对每个方案 $j \in C_n$ 的效用。在效用函数的表示中: $\mathbf{X}_{n,j}$ 为用户 n 对于方案 j 的特征属性, 例如方案所需的出行时间、费用, 以及用户的性别、收入等; ζ_n 为用户 n 的待估参数(即本地模型参数); $\epsilon_{n,j}$ 为用户 n 针对方案 j 的随机扰动效用。对于全局分布: μ 为本地参数 ζ_n 的均值, 表征群体水平偏好; Ω 为本地参数 ζ_n 的协方差, 代表群体偏好的差异程度。结合本地模型和全局分布, 依据贝叶斯理论, 可以得到




图2 联邦混合罗吉特模型

Fig. 2 Federated mixed Logit model

μ, Ω 和 ζ_n 的后验分布 $K(\cdot)$ 。

2.1 本地模型

为刻画个体出行偏好, 用户端分别构建各自的本地模型, 该模型遵循随机效用最大化假设^[23], 即用户总是选择其自身认知到的备选方案中效用最大的方案。

效用函数 $U_{n,j}$ 通常表示为

$$U_{n,j} = V_{n,j} + \epsilon_{n,j} = \mathbf{X}_{n,j} \zeta_n + \epsilon_{n,j} \quad (2)$$

式中: $V_{n,j}$ 为用户 n 对于方案 j 的可观测效用, 可进一步表示为关于特征属性 $\mathbf{X}_{n,j}$ 和本地模型参数 ζ_n 的线性函数 $V_{n,j}(\cdot)$ 。

当 $\epsilon_{n,j}$ 服从极值分布时, 可以将用户 n 选择方案 j 的选择概率函数表示为标准多项式罗吉特(Multinomial Logit, MNL)模型的概率函数 $P_{n,j}(\cdot)$, 即

$$P_{n,j}(\zeta_n) = \frac{\exp[V_{n,j}(\zeta_n)]}{\sum_{j'=1}^J \exp[V_{n,j'}(\zeta_n)]} \quad (3)$$

式中: $V_{n,j'}(\cdot)$ 为用户 n 对于不同选择方案 $j' \in C_n$ 的可观测效用。

2.2 全局分布

个体出行偏好大致遵循群体规律, 其异质性主要体现在对特征变量的偏好敏感程度上。例如, 用户大多偏爱出行时间短且费用少的出行方案, 但其愿意为缩短单位出行时间而多支付的出行费用却各不相同。基于标准 MXL 模型的建模思想, 假设个体出行偏好相互独立且服从同一分布, 以实现个体偏好的统一建模, 因此, 在中央服务器定义本地模型参数的全局分布服从正态分布 $\psi(\cdot)$ 。需要说明的是, 本文仅讨论符合正态分布的全局分布, 在具

体应用中,为精准表达特征变量的物理意义,全局分布也可定义为其他形式,如对数正态分布、均匀分布、约翰逊 SB 分布等^[24]。

综上,中央服务器可通过全局分布,关联各用户端的本地模型和用户数据。假设用户 n 面临 G_n 次历史选择情景,对于所有用户 B 的群选择集的对数似然表示 $L(\cdot)$ 为

$$L(d_n \forall n | \mu, \Omega, \zeta_n \forall n) = \prod_{n=1}^N \left\{ \prod_{g=1}^{G_n} \left[\prod_{j=1}^J (P_{n,j,g}(\zeta_n))^{h_{n,j,g}} \right] \cdot \phi(\zeta_n | \mu, \Omega) \right\} \quad (4)$$

式中: $P_{n,j,g}(\cdot)$ 为用户 n 在历史情景 g 下选择方案 j 的选择概率; $h_{n,j,g}$ 为 0-1 变量,如果用户 n 在历史情景 g 下选择方案 j 则为 1,否则为 0。

2.3 联合估计

通常情况下,离散选择建模采用数值最优化算法,以求解最大似然公式(4)所对应的模型参数^[25]。然而,由于式(4)没有封闭形式的解,不能直接进行求解,因此,本文采用贝叶斯估计方法将未知参数的先验信息与样本信息结合,再根据贝叶斯定义,得到联合后验分布。最后,使用马尔科夫链蒙特卡罗(Markov Chain Monto Carlo, MCMC)方法^[26]抽样模拟后验分布,据此推断未知参数。

首先,定义全局分布参数 μ 和 Ω 的无信息先验分布 $k(\cdot)$,其服从分布 $k(\mu) \sim \phi(\mu_0, A)$ 、 $k(\Omega) \sim \chi(Q, E_Q)$,其中:假设全局分布参数的群体水平偏好 μ 的初始值为 μ_0 ,它可设为任意值; A 为对角协方差矩阵,为保证后验扩散,矩阵 A 中的对角线元素可设为无穷大; $\chi(\cdot)$ 为 Inverse-Wishart 分布; Q 为本地模型参数的数量; E_Q 为 Q 维单位矩阵。

即 μ, Ω 和 ζ_n 的后验 $K(\cdot)$ 为

$$K(\mu, \Omega, \zeta_n \forall n | d_n \forall n) \propto L(d_n \forall n | \mu, \Omega, \zeta_n \forall n) \cdot k(\mu) k(\Omega) \propto \prod_{n=1}^N \left[\prod_{g=1}^{G_n} \left[\prod_{j=1}^J [P_{n,j,g}(\zeta_n)]^{h_{n,j,g}} \right] \cdot \phi(\zeta_n | \mu, \Omega) \right] k(\mu) k(\Omega) \quad (5)$$

综上,因联合后验公式(5)在形式上与标准 MXL 模型的经典 Allenby-Train 层次贝叶斯后验^[22]一致,因此,基于 FMXL 模型和贝叶斯估计原理,中央服务器仅需协同多个用户端上的本地选择模型,模拟出各用户选择集的联合后验分布,就能达到与集中式建模相同的效果。

3 FMXL 模型抽样算法

为在保护用户数据隐私的前提下求解 FMXL

模型,本文借鉴一种名为联邦学习的新兴计算范式。传统的联邦学习算法^[18]以全局损失函数最小为优化目标,中央服务器将部分训练任务分配给保有数据的用户端设备,使本地模型在全局目标的指引下达到最优,通过中央服务器和用户端的通信不断更新迭代模型,直至全局模型收敛至理想精度。与不同的是,本文的联邦学习算法实现了协同抽样过程,其目标是让本地模型参数的抽样值不断接近各方的后验分布,进而推断出联合后验分布式(5),使本地模型保留群体偏好的同时,可表征个体差异。

为实现上述目标,本文基于 MCMC 中最常用的吉布斯抽样方法,提出了 2 种联邦吉布斯抽样(Federated Gibbs Sampling, FGibbs)算法:标准联邦吉布斯抽样(Standardized FGibbs, SFGibbs)算法和聚合联邦吉布斯抽样(Aggregated FGibbs, AFGibbs)算法,二者共用一个整体流程,但在中央服务器中全局参数的运算过程存在差异。

3.1 标准联邦吉布斯抽样算法

经典的吉布斯抽样方法通过遍历所有参数分布区块,在所有参数的最新抽样下,对每一候选参数进行条件抽样,经过不断轮换迭代,构造出一条平稳分布的马尔科夫链,以实现目标分布的模拟^[27]。针对 FMXL 模型,根据式(5)可得到 μ, Ω 和 ζ_n 的条件抽样如下

$$K(\mu | \Omega, \zeta_n \forall n) \propto \phi(\zeta_n | \mu, \Omega) k(\mu) \quad (6)$$

$$K(\Omega | \mu, \zeta_n \forall n) \propto \phi(\zeta_n | \mu, \Omega) k(\Omega) \quad (7)$$

$$K(\zeta_n | \mu, \Omega) \propto \left[\prod_{g=1}^{G_n} \prod_{j=1}^J [P_{n,j,g}(\zeta_n)]^{h_{n,j,g}} \right] \cdot \phi(\zeta_n | \mu, \Omega) \quad (8)$$

因式(6)~(8)对应的抽样任务只依赖本地模型参数,所以中央服务器仅需收集用户端的最新抽样值,随之即完成全局分布参数 μ 和 Ω 的条件抽样。而式(8)对应的抽样任务涉及到与用户特征变量相关的计算,为保证原始数据不出本地,各用户端可依据本地数据,以及中央服务器广播的最新 μ, Ω 抽样值,完成 ζ_n 的条件抽样。

基于上述思想,本文提出 SFGibbs 算法,抽样步骤具体如下。

步骤 1: FMXL 模型初始化。用户端接收抽样指令,初始化本地离散选择模型,同时,中央服务器广播初始的全局分布参数 μ_0, Ω_0 。

步骤 2: 用户端抽样 ζ_n 。用户端根据各自持有的选择数据同时进行基于第 $y-1$ 次的抽样结果 μ_{y-1}, Ω_{y-1} 的条件抽样,其中: μ_{y-1} 为第 $y-1$ 次中央服务器

抽样得到的均值; Ω_{y-1} 为第 $y-1$ 次中央服务器抽样得到的协方差。各方的条件后验分布为式(8),因其不具备封闭形式,故采用 Metropolis-Hasting 算法获得用户 n 第 y 次抽样的模型参数 $\zeta_{n,y}$ 。

首先,获取用户 n 第 y 次抽样的候选模型参数 $\tilde{\zeta}_{n,y}$

$$\tilde{\zeta}_{n,y} = \zeta_{n,y-1} + \sqrt{\rho} \Lambda \mathbf{v} \quad (9)$$

式中: ρ 为随机游走步长; Λ 为 Ω 的 Cholesky 分解; $\mathbf{v}$ 为从标准正态分布 $\psi(0,1)$ 中抽样得到的 Q 个独立变量。

进一步地,从标准均匀分布中抽样得到接收标准 u ,并计算抽样接受率 θ

$$\theta = \frac{\prod_{g=1}^{G_n} \prod_{j=1}^J \left\{ [P_{n,j,g}(\tilde{\zeta}_{n,y})]^{h_{n,j,g}} \right\} \psi(\tilde{\zeta}_{n,y} | \boldsymbol{\mu}, \Omega)}{\prod_{g=1}^{G_n} \prod_{j=1}^J \left\{ [P_{n,j,g}(\zeta_{n,y-1})]^{h_{n,j,g}} \right\} \psi(\zeta_{n,y-1} | \boldsymbol{\mu}, \Omega)} \quad (10)$$

如果 $u < \theta$,接受 $\tilde{\zeta}_{n,y}$,并令 $\zeta_{n,y} = \tilde{\zeta}_{n,y}$;反之拒绝 $\tilde{\zeta}_{n,y}$,令 $\zeta_{n,y} = \zeta_{n,y-1}$ 。

步骤 3:本地模型上传。用户端分别将第 y 次抽样的本地模型参数 $\{\zeta_{1,y}, \dots, \zeta_{n,y}, \dots, \zeta_{N,y}\}$ 上传至中央服务器。

步骤 4:中央服务器抽样 $\boldsymbol{\mu}$ 。当中央服务器收集所有本地模型后,从条件后验公式(5)中抽取全局分布的均值。其中,由于 $K(\boldsymbol{\mu})$ 是扩散先验,式(6)可化简为多维正态分布 $\psi(\boldsymbol{\zeta}_y, \Omega_y/N)$,因此,第 y 次抽样的全局分布的均值 $\boldsymbol{\mu}_y$ 可以直接表示为

$$\boldsymbol{\mu}_y = \bar{\boldsymbol{\zeta}}_y + \Phi_{y-1} \boldsymbol{\omega} \quad (11)$$

$$\bar{\boldsymbol{\zeta}}_y = \frac{1}{N} \sum_{n=1}^N \boldsymbol{\zeta}_{n,y} \quad (12)$$

式中: Φ_{y-1} 为 Ω_{y-1}/N 的 Cholesky 分解; $\boldsymbol{\omega}$ 为从 Q 维标准正态分布中抽样得到的值。

步骤 5:中央服务器抽样 Ω 。 Ω 的条件后验为式(7),由于 Ω 的先验也是扩散的,式(8)可推导为自由度为 $Q+N$,尺度矩阵为 $QE_Q + N\boldsymbol{\gamma}$ 的 Inverse-Wishart 分布,其中, $\boldsymbol{\gamma}$ 为协方差,对应的计算公式如下

$$\boldsymbol{\gamma} = \frac{1}{N} \sum_{n=1}^N (\boldsymbol{\zeta}_{n,y} - \boldsymbol{\mu}_y) (\boldsymbol{\zeta}_{n,y} - \boldsymbol{\mu}_y)' \quad (13)$$

中央服务器第 y 次抽样的协方差 Ω_y 表示为

$$\Omega_y = \left[\sum_{r=1}^{Q+N} (\boldsymbol{\Gamma} \boldsymbol{\omega}_r) (\boldsymbol{\Gamma} \boldsymbol{\omega}_r)' \right]^{-1} \quad (14)$$

式中: $\boldsymbol{\Gamma}$ 为 $(QE_Q + N\boldsymbol{\gamma})^{-1}$ 的 Cholesky 分解; $\boldsymbol{\omega}_r$ 为第 r 次从 Q 维标准正态分布中抽样得到的抽样值。

步骤 6:全局分布更新。中央服务器向用户端广播第 y 次抽样的全局分布参数 $\boldsymbol{\mu}_y, \Omega_y$ 。

重复步骤 2~6,直至抽样平稳,将平稳阶段的抽样均值作为模型参数的估计值。

3.2 聚合联邦吉布斯抽样算法

在联邦学习中,联邦平均(Federated Averaging, FedAvg)算法^[18]作为一种经典的聚合算法被广泛使用。在该算法中,用户端在本地训练后,上传本地模型参数,中央服务器对来自各个用户端的模型参数进行加权平均,从而完成一次系统层面的迭代。受 FedAvg 算法启发,本文还提出一种 AFGibbs 算法。类似地,中央服务器不进行条件抽样,而是直接聚合全局分布参数。尽管上述聚合机制不能对后验结果进行准确地推理,但它能够简化计算过程,有助于搜索符合联邦过程的全局最优配置。

AFGibbs 算法的具体抽样步骤仅需将 SFGibbs 算法中的步骤 4、5 进行调整,具体如下。

AFGibbs 算法步骤 4:中央服务器聚合 $\boldsymbol{\mu}$ 。在第 y 次聚合时,当中央服务器收集到所有本地模型后,直接聚合获得全局分布的均值 $\boldsymbol{\mu}_y$

$$\boldsymbol{\mu}_y = \frac{1}{N} \sum_{n=1}^N \boldsymbol{\zeta}_{n,y} \quad (15)$$

AFGibbs 算法步骤 5:中央服务器聚合 Ω 。第 y 次聚合时的协方差 Ω_y 的计算公式为

$$\Omega_y = \frac{1}{N} \sum_{n=1}^N (\boldsymbol{\zeta}_{n,y} - \boldsymbol{\mu}_y) (\boldsymbol{\zeta}_{n,y} - \boldsymbol{\mu}_y)' \quad (16)$$

总的来说,2 种联邦吉布斯算法以隐私保护(即数据不出本地)为前提,通过模型参数的通讯交互(即步骤 3、6),协同完成本地模型的训练,以实现 FMXL 模型的贝叶斯后验模拟。这不仅保证了个体偏好的异质性,也提高了用户端资源的利用率,降低了中央服务器的运行负载,因此,所提模型和求解算法可以很好地保证数据的隐私处理、资源的高效协作、用户的异质推荐。

4 试验与结果分析

为验证所提模型和算法面向个体出行推荐的性能,对离线估计和在线估计 2 种典型推荐场景进行模拟试验。离线场景主要模拟推荐系统在生成足量用户历史选择数据后,周期性地更新个体出行效用函数,侧重对用户出行画像(即本文的个体出行偏好)的精准学习能力,即预测的精确性;在线场景模拟的是推荐系统在短期内高频率地更新个体出行效用函数的情况,强调推荐的实时决策和响应能力,即算法的时效性。

4.1 数据集与建模

本文使用 Swiss Metro 数据集^[28],该数据集是 1998 年 3 月在圣加伦和瑞士日内瓦之间的火车上收集的,包含 1 291 名乘客的调查数据。在该调查中,共提供了 9 种假设的出行选择情景和 3 种出行方式选择(私家车、瑞士地铁、火车),每种出行方式的特征变量有出行时间、瑞士地铁与火车的发车时距、出行费用(私家车的燃油费与停车费、瑞士地铁与火车的票价)等。被调查者需在不同情景下对 3 种出行方式做出选择。在原数据集的基础上对数据进行清理,即剔除私家车保有量为 0 或办理公交年卡等出行选择偏差较大的调查对象,保留了 862 人的数据作为试验数据集。

此外,本文采用支付意愿函数^[29],针对私家车、瑞士地铁、火车 3 种出行方式,选取不同方式 j 的出行费用 W_j 和出行时间 T_j 两种特征,分别计算用户 n 面对不同出行方式的效用 $U_{n,0}$ 、 $U_{n,1}$ 、 $U_{n,2}$

$$U_{n,0} = [\alpha_{n,0} - W_0 - T_0 \exp(\beta_{T,n})] / \exp(\beta_{\lambda,n}) + \epsilon_{n,0} \quad (17)$$

$$U_{n,1} = [\alpha_{n,1} - W_1 - T_1 \exp(\beta_{T,n})] / \exp(\beta_{\lambda,n}) + \epsilon_{n,1} \quad (18)$$

$$U_{n,2} = [-W_2 - T_2 \exp(\beta_{T,n})] / \exp(\beta_{\lambda,n}) + \epsilon_{n,2} \quad (19)$$

式中: $\alpha_{n,0}$ 和 $\alpha_{n,1}$ 分别为用户 n 对于私家车选择项的固有常量和瑞士地铁选择项的固有常量,其中火车为参照组,其相应的固有常量为 0; W_0 、 W_1 和 W_2 分别为私家车、瑞士地铁和火车 3 种出行方式的出行费用; T_0 、 T_1 和 T_2 分别为私家车、瑞士地铁和火车 3 种出行方式的出行时间; $\beta_{T,n}$ 和 $\beta_{\lambda,n}$ 分别为用户 n 对于出行时间上的时间系数和规模上的规模系数,以上 2 项均转化为指数形式,使系数始终为正值,以反映出行时间和费用对出行效用产生的负面效应; $\epsilon_{n,0}$ 、 $\epsilon_{n,1}$ 和 $\epsilon_{n,2}$ 分别为用户 n 对于私家车、瑞士地铁和火车 3 种出行方式的随机效用,3 种随机效用均服从极值分布。

4.2 试验设置及场景

模拟 1 个中央服务器和 862 个用户端的计算及通信环境,其中,通信总带宽为 20 MHz,中央服务器的 CPU 处理频率为 2.5 GHz;设备的传输功率为 0.2~1.0 W,CPU 频率为 1.5~2.0 GHz。为模拟 2 种联邦吉布斯抽样算法在出行推荐中的偏好估计过程,本文分别搭建离线和在线 2 组试验场景。

离线场景:以所有用户的前 8 次选择为训练样本,进行 1 次模型参数估计,将第 9 次选择作为测试样本。

在线场景:假设用户数量及其前 8 次选择数据分 15 轮逐轮增加,其中,初始用户数为 100,以 10%~12%的速率逐轮加入训练;用户最初仅完成 1 次或 2 次选择,每轮进行 1 次或 2 次选择。每一轮将已参与用户的历史选择作为训练样本,进行 1 次模型参数估计。同时,挑选测试样本,包含:已参与用户即将进行的下一次选择;未参与用户的首次选择。

2 种场景下单次模型参数估计的抽样迭代均为 2 000 次,其中前 1 000 次用于过渡不稳定采样阶段,保留后 1 000 次抽样结果用于估计后验均值。

4.3 评价指标与基准方法

本文主要从精确性和时效性 2 个方面,选取不同的指标和基准方法,对 FMXL 模型的 2 种算法进行对比评价。

4.3.1 预测的精确性

采用对数似然值 L 和预测率 R 作为评价指标,对应表达式分别为

$$L = \sum_{s=1}^S \lg(P_s) \quad (20)$$

$$R = \frac{1}{S} \sum_{s=1}^S h_s \quad (21)$$

式中: P_s 为样本 s 的选择项的概率; S 为测试样本数量; h_s 为针对样本 s 的 0-1 变量,如果预测的样本选择项与实际选择项相同则为 1,否则为 0。

针对模型精确性与基准方法 MNL-Gibbs 进行对比,即在集中式计算模式下,采用吉布斯抽样方法实现标准 MNL 模型的数值估计。

4.3.2 算法的时效性

将实现单次模型参数估计的训练时间作为指标。训练时间包含计算和通信 2 部分。对于集中式训练,需要终端设备集中上传原始数据,再由中央服务器统一计算。而本文所述的联邦式训练则通过网络进行模型参数的交换。集中式训练和联邦式训练的训练时间 T_C 和 T_F 分别表示为

$$T_C = \sum_{i=1}^I [T_{\vartheta,e}^{(i)} + \max_{\tau \in B_1} (T_{\tau,x}^{(i)})] \quad (22)$$

$$T_F = \sum_{i=1}^I [T_{\vartheta,e}^{(i)} + \max_{\tau \in B_1} (T_{\tau,x}^{(i)} + T_{\tau,e}^{(i)})] \quad (23)$$

式中: B_1 为用户集合 B 中参与训练的总用户设备; I 为抽样迭代次数; $T_{\tau,e}^{(i)}$ 和 $T_{\vartheta,e}^{(i)}$ 分别为第 i 次迭代时用户设备 τ 和中央服务器 ϑ 的计算用时; $T_{\tau,x}^{(i)}$ 为第 i 次迭

代时用户设备 τ 的通信用时^[30]。

针对模型的时效性与基准方法 MXL-Gibbs 进行对比,即在集中式计算模式下,采用吉布斯抽样方法实现标准 MXL 模型的数值估计。

4.4 试验结果与分析

为保证试验的完备性,本文采用相同的评价指标和基准方法,在 2 种推荐场景下对所提算法的性能进行评估。

4.4.1 离线场景的估计结果分析

表 1、2 分别记录了 MNL-Gibbs、FMXL-SFGibbs 和 FMXL-AFGibbs 的模型参数估计结果和精确性。由表 1、2 可见:相较于标准 MNL 模型,FMXL 模型因

捕获了用户对所有特征项的偏好异质性,使得模型的拟合度明显改善,并且预测率提高了约 12.5%。

表 3 记录了 MXL-Gibbs、FMXL-SFGibbs 和 FMXL-AFGibbs 的时效性。由表 3 可见:MXL-Gibbs 的计算时间约为联邦吉布斯抽样算法的 3~4 倍;其通信时间约为联邦吉布斯抽样算法的 7 倍。因为离线估计的 MXL-Gibbs 需要周期性地将用户产生的原始数据统一传送至中央服务器中,而 2 种联邦吉布斯抽样算法可在各用户端并行化执行,且每次通信只需传送约 16 个字节左右的数据(模型参数),大大缩短了联邦吉布斯抽样算法的计算和通信时间。

表 1 离线场景的模型参数估计结果

Table 1 Model parameter estimation results in offline scenario

指标	标准 MNL 模型		FMXL 模型							
	MNL-Gibbs		FMXL-SFGibbs				FMXL-AFGibbs			
	固定参数		μ		Ω		μ		Ω	
	均值	标准差	均值	标准差	均值	标准差	均值	标准差	均值	标准差
α_0	1.313	0.096	0.509	0.086	1.406	0.178	0.529	0.058	0.954	0.130
α_1	1.286	0.096	0.251	0.065	0.436	0.059	0.277	0.043	0.288	0.038
β_T	0.559	0.052	-0.006	0.070	1.421	0.218	-0.045	0.048	1.362	0.205
β_k	0.069	0.045	-1.920	0.197	0.915	0.139	-1.880	0.195	0.722	0.108

表 2 离线场景的精确性对比

Table 2 Accuracy comparison in offline scenario

指标	标准 MNL 模型	FMXL 模型	
	MNL-Gibbs	FMXL-SFGibbs	FMXL-AFGibbs
L	-711.325	-553.568	-558.169
R	0.649	0.772	0.770

表 3 离线场景的时效性对比

Table 3 Timeliness comparison in offline scenario

指标	MXL 模型	FMXL 模型	
	MXL-Gibbs	FMXL-SFGibbs	FMXL-AFGibbs
计算时间/s	9.305	3.331	2.151
通信时间/s	5.184	0.746	0.746
总计/s	14.489	4.077	2.897

综合表 1~3 比较 FMXL-SFGibbs 和 FMXL-AFGibbs。需要强调的是,因为 FMXL-SFGibbs 的所有运算均遵循标准的条件抽样,所以 FMXL-SFGibbs 和 MXL-Gibbs 的模型参数估计结果和精确性上完全相同。由表 1~3 可见:由于 FMXL-AFGibbs 的聚合机制相当于将全局分布的最大后验概率对应的参数作为抽样值,因此,使本地模型参数 ζ_n 偏向所有本地模型的均值,导致协方差 Ω 对角

线上的值(各参数的方差)均低于 FMXL-SFGibbs,因此,对数似然值和预测率略微低于 FMXL-SFGibbs;但 FMXL-AFGibbs 可使服务器的运算更简单,因而耗时更短。总体而言,两者在精确性上大致相同(相差 0.01%),但是 FMXL-AFGibbs 在时效性方面表现更好。

4.4.2 在线场景的估计结果分析

在线估计场景可分为 2 个阶段,前 8 轮为用户参与阶段,即用户逐轮加入,到第 8 轮时所有用户全部参与训练;后 7 轮为用户选择阶段,到第 15 轮时用户完成全部选择。

图 3 为 MNL-Gibbs、FMXL-SFGibbs 和 FMXL-AFGibbs 的模型训练情况。由图 3 可见:在用户参与阶段,FMXL 模型的预测率和对数似然值都呈上升趋势。从用户选择阶段的第 1 轮(实际第 9 轮)开始,模型的实时预测率就已高达 77%,且之后一直维持在这一水平;在第 10 轮时,对数似然值也达到最大值,该模型在一定程度上克服了传统推荐系统中向新用户进行推荐的冷启动问题。另外,因为标准 MNL 模型在整个在线估计过程中只能反映群体水平的偏好,因此,即使有更多的用户选择样本加




图3 在线场景的精确性对比

Fig. 3 Accuracy comparison in online scenario

入,该模型的预测率仍然很低,其对数似然值达到-700后不再上升。

图4展示了在线估计 MXL-Gibbs、FMXL-SFGibbs 和 FMXL-AFGibbs 的时效性变化情况。由图4可见:3种估计方法的计算时间和通信时间均在用户参与阶段逐渐增长,并在用户选择阶段基本稳

定不变。值得注意的是,在线估计场景下,MXL-Gibbs 的通信时间小于2种联邦吉布斯抽样算法,这是由于在线估计下的选择数据分批次上传,单次传输的数据量较少。但是,在整个模型更新过程中,通信时间只占总耗时的一小部分,因此,从总体上看,2种联邦吉布斯抽样算法的时效性依然优于 MXL-Gibbs。




图4 在线场景的时效性对比

Fig. 4 Timeliness comparison in online scenario

综合图3、4比较 FMXL-SFGibbs 和 FMXL-AFGibbs。在用户参与阶段,尽管 FMXL-AFGibbs 的对数似然值低于 FMXL-SFGibbs,但其预测率略高,通过图3、4表明:当数据量较少时,FMXL-AFGibbs 的模型偏向性反而使得群体均值 μ 能够更好地表征未参与用户的偏好,进一步改善了推荐的冷启动问题;在用户选择阶段,二者的预测性能和模型拟合程度无明显差别;同时,FMXL-AFGibbs 的计算时间较 FMXL-SFGibbs 更短,因此,FMXL-AFGibbs 的时效性略优于 FMXL-SFGibbs。

综上所述,面向2种典型推荐场景,对 FMXL

模型及联邦吉布斯算法进行了精确性与时效性的对比,可以看出本文模型不但可实现个体数据的隐私化处理,也提高了模型的适应性与可扩展性。具体而言:面向离线场景,所提2种算法均继承了数理模型的可解释能力,通过构建本地模型与全局分布实现对个体与群体行为的精准分析,其中 SFGibbs 算法因能准确推理后验,而更适合离线场景;而面向在线场景,所提算法则突显了联邦学习的分布式训练优势,通过各边缘端的并行化运算,可实现用户偏好的快速估计,其中 AFGibbs 算法因进一步压缩了训练时间,而更适合在线场景。

5 结 语

(1) 鉴于出行推荐是一种提升交通系统智能化水平的重要手段, 本文首次定义了面向个体出行隐私化推荐的联邦学习问题。针对传统集中式模型训练存在的算力闲置、隐私泄露等问题, 借鉴联邦学习计算范式, 本文提出了 FMXL 模型; 同时, 为了实现模型的隐私化和协同化估计, 提出了标准和聚合 2 种联邦吉布斯抽样算法, 在保护数据隐私安全的同时, 充分利用各用户端自身算力实现并行的模型估算, 有效提高了模型的训练效率。

(2) 使用公开数据集 Swiss Metro 进行试验, 结果表明, 2 种联邦吉布斯抽样算法均能在保护个体数据的前提下, 实现高精度、高效率的模型拟合。总体上, 无论是面向离线还是在线场景, 所提模型和算法均有助于构建用户出行画像, 并及时反馈用户的行为变化, 具备很高的适应性与可扩展性。

(3) 需要指出的是, 由于本文首次将联邦学习与统计学模型相结合, 是一种全新的尝试, 因此, 现阶段的研究仍面临一些开放性挑战: AFGibbs 算法尽管在预测率上与 SFGibbs 算法表现一致, 且计算耗时更少, 能够更好地满足个性化推荐、快速响应的需求, 但其得到的后验概率分布与实际后验存在偏差, 因此, 在未来的研究中, 可以优化中央服务器的聚合机制, 进一步提高训练速度的同时, 更准确地拟合 FMXL 模型; 本文采用同步训练机制, 即中央服务器需等待所有本地模型成功上传后, 才能进行全局分布的更新, 然而, 当应用于更大规模的联邦训练场景时, 因用户端资源(如计算、通信能力等)普遍存在差异, 此时, 同步训练机制易遭受短板效应, 进而影响整体的训练速率, 因此, 未来可以通过优化训练的时序, 如研究异步训练机制, 使联邦吉布斯抽样算法更稳定、更高效。

参 考 文 献 :

References :

- [1] 彭宏勤, 张国伍. 未来城市交通及其对未来城市发展影响[J]. 交通运输系统工程与信息, 2020, 20(1): 2-5.
PENG Hong-qin, ZHANG Guo-wu. Future urban traffic and its influence on cities development[J]. Journal of Transportation Systems Engineering and Information Technology, 2020, 20(1): 2-5. (in Chinese)
- [2] LIU Yang, LYU Cheng, LIU Zhi-yuan, et al. Exploring a large-scale multi-modal transportation recommendation system[J]. Transportation Research Part C: Emerging Technologies, 2021, 126: 103070.

- [3] DAS D, SAHOO L, DATTA S. A survey on recommendation system[J]. International Journal of Computer Applications, 2017, 160(7): 6-10.
- [4] ZHANG Qian, LU Jie, JIN Yao-chu. Artificial intelligence in recommender systems[J]. Complex and Intelligent Systems, 2021, 7(1): 439-457.
- [5] CUI Ge, LUO Jun, WANG Xin. Personalized travel route recommendation using collaborative filtering based on GPS trajectories[J]. International Journal of Digital Earth, 2018, 11(3): 284-307.
- [6] WEN Y T, YEO J Y, PENG W C, et al. Efficient keyword-aware representative travel route recommendation[J]. IEEE Transactions on Knowledge and Data Engineering, 2017, 29(8): 1639-1652.
- [7] 孙全明, 常磊, 马钺, 等. 基于图嵌入和 CaGBDT 的多模式出行推荐[J]. 北京邮电大学学报, 2021, 44(5): 81-87, 106.
SUN Quan-ming, CHANG Lei, MA Cheng, et al. Multi-modal transportation recommendation based on graph embedding and CaGBDT[J]. Journal of Beijing University of Posts and Telecommunications, 2021, 44(5): 81-87, 106. (in Chinese)
- [8] 杨敏, 李宏伟, 任怡凤, 等. 基于旅客异质性画像的公铁联程出行方案推荐方法[J]. 清华大学学报(自然科学版), 2022, 62(7): 1220-1227.
YANG Min, LI Hong-wei, REN Yi-feng, et al. Road-rail intermodal travel recommendations based on a passenger heterogeneity profile[J]. Journal of Tsinghua University (Science and Technology), 2022, 62(7): 1220-1227. (in Chinese)
- [9] SONG Xiang, DANAF M, ATASOY B, et al. Personalized menu optimization with preference updater: a Boston case study[J]. Transportation Research Record, 2018, 2672(8): 599-607.
- [10] BALBONTIN C, HENSHER D A, COLLINS A T. How to better represent preferences in choice models: the contributions to preference heterogeneity attributable to the presence of process heterogeneity[J]. Transportation Research Part B: Methodological, 2019, 122: 218-248.
- [11] GODDARD M. The EU general data protection regulation (GDPR): European regulation that has a global impact[J]. International Journal of Market Research, 2017, 59(6): 703-705.
- [12] YANG Qiang, LIU Yang, CHEN Tian-jian, et al. Federated machine learning: concept and applications[J]. ACM Transactions on Intelligent Systems and Technology, 2019, 10(2): 1-19.
- [13] JIAN Wei-tao, CHEN Kun-xu, HE Jun-shu, et al. A federated personal mobility service in autonomous transportation systems[J]. Mathematics, 2023, 11(12): 2693.
- [14] LIU Sheng, CHEN Qi-yang, YOU Lin-lin. Fed2A: federated learning mechanism in asynchronous and adaptive modes[J]. Electronics, 2022, 11(9): 1393.
- [15] WANG Si-hua, CHEN Ming-zhe, YIN Chang-chuan, et al. Federated learning for task and resource allocation in wireless high-altitude balloon networks[J]. IEEE Internet of Things

- Journal, 2021, 8(24): 17460-17475.
- [16] CHENG Ke-wei, FAN Tao, JIN Yi-lun, et al. Secureboost: a lossless federated learning framework[J]. IEEE Intelligent Systems, 2021, 36(6): 87-98.
- [17] ZHU Hang-yu, JIN Yao-chu. Multi-objective evolutionary federated learning[J]. IEEE Transactions on Neural Networks and Learning Systems, 2020, 31(4): 1310-1322.
- [18] MCMAHAN B, MOORE E, RAMAGE D, et al. Communication-efficient learning of deep networks from decentralized data[C]// SINGH A, ZHU J. Proceedings of the 20th International Conference on Artificial Intelligence and Statistics. Brookline: Microtome Publishing, 2017: 1273-1282.
- [19] GELFAND A E. Gibbs sampling[J]. Journal of the American Statistical Association, 2000, 95(452): 1300-1304.
- [20] MCFADDEN D. The measurement of urban travel demand[J]. Journal of Public Economics, 1974, 3(4): 303-328.
- [21] HENSHER D A, GREENE W H. The mixed logit model: the state of practice[J]. Transportation, 2003, 30: 133-176.
- [22] SONG Xiang. Personalization of future urban mobility[D]. Cambridge: Massachusetts Institute of Technology, 2018.
- [23] MCFADDEN D, TRAIN K. Mixed MNL models for discrete response[J]. Journal of Applied Econometrics, 2000, 15(5): 447-470.
- [24] TRAIN K. Mixed logit with a flexible mixing distribution[J]. Journal of Choice Modelling, 2016, 19: 40-53.
- [25] LEE L F. Simulated maximum likelihood estimation of dynamic discrete choice statistical models some Monte Carlo results[J]. Journal of Econometrics, 1997, 82(1): 1-35.
- [26] BANSAL P, KRUEGER R, BIERLAIRE M, et al. Bayesian estimation of mixed multinomial logit models: advances and simulation-based evaluations [J]. Transportation Research Part B: Methodological, 2020, 131: 124-142.
- [27] CHIB S, GREENBERG E. Understanding the metropolis-Hastings algorithm[J]. The American Statistician, 1995, 49(4): 327-335.
- [28] DANAF M, BECKER F, SONG Xiang, et al. Online discrete choice models: applications in personalized recommendations[J]. Decision Support Systems, 2019, 119: 35-45.
- [29] BEN-AKIVA M, MCFADDEN D, TRAIN K. Foundations of stated preference elicitation: consumer behavior and choice-based conjoint analysis[J]. Foundations and Trends in Econometrics, 2019, 10(1/2): 1-144.
- [30] DINH C T, TRAN N H, NGUYEN M N, et al. Federated learning over wireless networks: convergence analysis and resource allocation[J]. IEEE/ACM Transactions on Networking, 2020, 29(1): 398-409.